

第一题

与行为 α_i 相关联的损失为：

$$R(\alpha_i|\mathbf{x}) = \sum_{j=1}^c \lambda(\alpha_i|\omega_j) P(\omega_j|\mathbf{x}) \quad (1)$$

$R(\alpha_i|\mathbf{x})$ 是和行为 α_i 有关的条件风险，行为由决策结果指定，则总风险由

$$R = \int R(\alpha(\mathbf{x})|\mathbf{x}) p(\mathbf{x}) d\mathbf{x} \quad (2)$$

给出，其中 $\alpha(\mathbf{x})$ 定义了通过每种可能的观测应该采取的行为。显然，当我们选择 $\alpha(\mathbf{x})$ 使得 $R(\alpha(\mathbf{x}))$ 对于每一个 \mathbf{x} 尽量小，则总风险将被最小化。

根据题目，误差函数定义为：

$$\lambda(\alpha_i|\omega_j) = \begin{cases} 0, & i = j \quad i, j = 1, \dots, c \\ \lambda_r, & i = c + 1 \\ \lambda_s, & otherwise \end{cases} \quad (3)$$

将 (3) 式代入 (1) 式得：

$$R_i(x) = \begin{cases} \lambda_s[1 - P(\omega_j|\mathbf{x})], & i = 1, \dots, c \\ \lambda_r, & reject \end{cases} \quad (4)$$

因此当拒识风险大于判断风险即 $\lambda_r > \lambda_s[1 - P(\omega_j|\mathbf{x})]$ 时，我们值得做出判定。此时， $i = 1, \dots, c$ ，为了最小化平均误差概率我么需要选取 i 使得后验概率 $P(\omega_j|\mathbf{x})$ 最大，即

$$\arg \min_i = \begin{cases} \arg \max_i P(\omega_j|\mathbf{x}), & if \max_i P(\omega_j|\mathbf{x}) > 1 - \lambda_r/\lambda_s \\ reject, & otherwise \end{cases} \quad (5)$$

证毕。当拒识代价 $\lambda_r = 0$ 且判断风险 $\lambda_s > 0$ 时，拒识风险永远不会大于判断风险，永远会拒识。当 $\lambda_r > \lambda_s$ 时，拒识代价永远大于判定，不会发生拒识的现象。

第二题

(a)

条件概率密度的分布函数为：

$$p(x|\omega_i) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}\left(\frac{x-\mu_i}{\sigma}\right)^2} \quad (6)$$

最小化误差概率条件下的贝叶斯决策规则为：

$$\text{如果 } P(\omega_1|x) > P(\omega_2|x), \text{ 判别为 } \omega_1, \text{ 否则判别为 } \omega_2 \quad (7)$$

我们只考虑二分类问题，假设分类器以某种方式将空间分为两个区域 R_1 和 R_2 。错误以两种可能的形式出现：真实类别为 ω_1 而观测值落入 R_2 或真实类别为 ω_2 而观测值落入 R_1 所以误差概率为：

$$\begin{aligned} P_e &= P(x \in R_2, \omega_1) + P(\mathbf{x} \in R_1, \omega_2) \\ &= P(x \in R_2|\omega_1)P(\omega_1) + P(\mathbf{x} \in R_1, \omega_2)P(\omega_2) \\ &= \int_{R_2} p(\mathbf{x}|\omega_1)P(\omega_1)dx + \int_{R_1} p(\mathbf{x}|\omega_2)P(\omega_2)dx \end{aligned} \quad (8)$$

因为 $P(\omega_1) = P(\omega_2)$ ，根据贝叶斯公式及式 (7)，可得最小误差分类的判决边界为过两个高斯分布的中点且垂直于 x 轴的直线。所以误

差为（不失一般性，我们假设 $\mu_1 \leq \mu_2$ ）：

$$\begin{aligned}
 P_e &= \frac{1}{2\sqrt{2\pi}\sigma} \left[\int_{-\infty}^{\frac{\mu_1+\mu_2}{2}} e^{-\frac{1}{2}\left(\frac{x-\mu_2}{\sigma}\right)^2} dx + \int_{\frac{\mu_1+\mu_2}{2}}^{+\infty} e^{-\frac{1}{2}\left(\frac{x-\mu_1}{\sigma}\right)^2} dx \right] \\
 &= \frac{1}{\sqrt{2\pi}\sigma} \int_{\frac{\mu_1+\mu_2}{2}}^{+\infty} e^{-\frac{1}{2}\left(\frac{x-\mu_1}{\sigma}\right)^2} dx \quad \text{换元可得：} \\
 &= \frac{1}{\sqrt{2\pi}} \int_{\frac{\mu_2-\mu_1}{2\sigma}}^{+\infty} e^{-\frac{1}{2}\mu^2} d\mu
 \end{aligned} \tag{9}$$

证毕。（因为证明过程假设 $\mu_1 \leq \mu_2$ ，所以免于使用绝对值符号。）

(b)

已知

$$P_e \leq \frac{1}{\sqrt{2\pi}a} e^{-\frac{a^2}{2}} \tag{10}$$

当 a 趋于无穷大时，式 (10) 中分母趋于无穷大，分子趋于 0，所以 P_e 趋于 0。

第三题

(a)

d 维多元正态密度函数的形式为：

$$p(\mathbf{x}) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} \exp\left[-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^t \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu})\right] \tag{11}$$

其中 \mathbf{x} 是一个 d 维列向量， $\boldsymbol{\mu}$ 是 \mathbf{x} 的 d 维均值指向量， Σ 是 \mathbf{x} 的 $d \times d$ 维协方差矩阵。

(b)

当每一类的协方差矩阵不相等时，判别函数为：

$$g_i(\mathbf{x}) = \mathbf{x}^t W_i \mathbf{x} + \mathbf{w}_i^t \mathbf{x} + \omega_{i0} \tag{12}$$

其中

$$\begin{aligned} W_i &= -\frac{1}{2}\Sigma_i^{-1} \\ \mathbf{w}_i &= \Sigma_i^{-1}\boldsymbol{\mu}_i \\ \omega_{i0} &= -\frac{1}{2}\boldsymbol{\mu}_i^t \Sigma_i^{-1} \boldsymbol{\mu}_i - \frac{1}{2} \ln |\Sigma_i| + \ln P(\omega_i) \end{aligned}$$

当每一类的协方差矩阵都相同时（设均为 Σ ），判别函数为：

$$g_i(\mathbf{x}) = \mathbf{w}_i^t \mathbf{x} + \omega_{i0} \quad (13)$$

其中

$$\begin{aligned} \mathbf{w}_i &= \Sigma^{-1} \boldsymbol{\mu}_i \\ \omega_{i0} &= -\frac{1}{2} \boldsymbol{\mu}_i^t \Sigma^{-1} \boldsymbol{\mu}_i + \ln P(\omega_i) \end{aligned}$$

(c)

当协方差矩阵奇异时，协方差矩阵的逆不存在且行列式的值为 0，不可计算。说明特征有冗余信息，可以通过 PCA、SVD 分解降维，使用降维后的协方差矩阵。

第四题

令两个判别函数式 (13) 相等，得到的边界面方程为：

$$\mathbf{w}^t (\mathbf{x} - \mathbf{x}_0) = 0 \quad (14)$$

其中

$$\mathbf{w} = \Sigma^{-1}(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j) \quad (15)$$

$$\mathbf{x}_0 = -\frac{1}{2}(\boldsymbol{\mu}_i + \boldsymbol{\mu}_j) - \frac{\ln[P(\omega_i)/P(\omega_j)]}{(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^t \Sigma^{-1}(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)}(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j) \quad (16)$$

欲使得判定面不过 $\boldsymbol{\mu}_1$ 与 $\boldsymbol{\mu}_2$ 之间的区域，临界条件为零点是 $\boldsymbol{\mu}_1$ 或

μ_2 两点。若零点不在 μ_1 和 μ_2 之间, 则有:

$$\mathbf{w}_t(\mu_1 - \mathbf{x}_0) * \mathbf{w}_t(\mu_2 - \mathbf{x}_0) > 0 \quad (17)$$

解得

$$\left| \ln \frac{P(\omega_1)}{P(\omega_2)} \right| > \frac{1}{2}(\mu_1 - \mu_2)^t \Sigma^{-1}(\mu_1 - \mu_2) \quad (18)$$

第五题

(a)

由于样本是独立同分布的, 则有:

$$P(z_{i_1}, \dots, z_{i_n} | P(\omega_i)) = \prod_{k=1}^n P(z_{i_k} | P(\omega_i)) \quad (19)$$

因为对于任意第 k 个样本

$$P(z_{i_k} = 1 | \omega_i) = P(\omega_i) = P(\omega_i)^{z_{i_k}}$$

$$P(z_{i_k} = 0 | \omega_i) = 1 - P(\omega_i) = (1 - P(\omega_i))^{1-z_{i_k}}$$

所以

$$P(z_{i_1}, \dots, z_{i_n} | P(\omega_i)) = \prod_{k=1}^n P(\omega_i)^{z_{i_k}} (1 - P(\omega_i))^{1-z_{i_k}} \quad (20)$$

证毕。

(b)

使用最大似然估计估计先验概率, 等价于求似然估计取对数的最大

值，即求

$$\ln P(z_{i_1}, \dots, z_{i_n} | P(\omega_i)) = \ln P(\omega_i) \sum_{k=1}^n z_{i_k} + \ln(1 - P(\omega_i)) \sum_{k=1}^n (1 - z_{i_k}) \quad (21)$$

的最大值。计算偏导数得

$$\frac{\partial L}{\partial P(\omega_i)} = \sum_{k=1}^n \left(\frac{z_{i_k}}{P(\omega_i)} - \frac{1 - z_{i_k}}{1 - P(\omega_i)} \right) \quad (22)$$

令偏导为 0，化简

$$\sum_{k=1}^n \left(\frac{z_{i_k}}{P(\omega_i)} - \frac{1 - z_{i_k}}{1 - P(\omega_i)} \right) = \sum_{k=1}^n \frac{z_{i_k} - P(\omega_i)}{P(\omega_i)(1 - P(\omega_i))} \quad (23)$$

由于式 (23) 中 $P(\omega_i)$ 和 $1 - P(\omega_i)$ 均不可能为 0，则只能分子为 0，即

$$\hat{P}(\omega_i) = \frac{1}{n} \sum_{k=1}^n z_{ik} \quad (24)$$

证毕。

第六题

(a) 根据期望定义公式，得

$$\begin{aligned} \hat{\mu}_{n+1} &= \frac{1}{n+1} \sum_{i=1}^{n+1} x_k \\ &= \frac{1}{n+1} \left(\sum_{i=1}^n x_k + x_{n+1} \right) \\ &= \frac{1}{n+1} (n\hat{\mu}_n + x_{n+1}) \\ &= \hat{\mu}_n + \frac{1}{n+1} (x_{n+1} - \hat{\mu}_n) \end{aligned} \quad (25)$$

根据方差定义公式，得

$$\begin{aligned} C_{n+1} &= \frac{1}{n} \sum_{k=1}^{n+1} (x_k - \hat{\mu}_{n+1})(x_k - \hat{\mu}_{n+1})^t \\ &= \frac{1}{n} \sum_{k=1}^n (x_k - \hat{\mu}_{n+1})(x_k - \hat{\mu}_{n+1})^t + (x_{n+1} - \hat{\mu}_{n+1})(x_{n+1} - \hat{\mu}_{n+1})^t \end{aligned}$$

将式 (25) 代入，且令 $\frac{1}{n+1}(x_{n+1} - \hat{\mu}_n)$ 为 Y ，得

$$= \frac{1}{n} \sum_{k=1}^n (x_k - \hat{\mu}_n - Y)(x_k - \hat{\mu}_n - Y)^t + (x_{n+1} - \hat{\mu}_{n+1})(x_{n+1} - \hat{\mu}_{n+1})^t$$

令 $(x_{n+1} - \hat{\mu}_{n+1})(x_{n+1} - \hat{\mu}_{n+1})^t$ 为 Z ，得

$$\begin{aligned} &= \frac{1}{n} \sum_{k=1}^n [(x_k - \hat{\mu}_n)(x_k - \hat{\mu}_n)^t - (x_k - \hat{\mu}_n)Y^t - Y(x_k - \hat{\mu}_n)^t + YY^t] + Z \\ &= \frac{n-1}{n} C_n + \frac{1}{n} \sum_{k=1}^n [(\hat{\mu}_n - x_k)Y^t + Y(\hat{\mu}_n - x_k)^t + YY^t] + Z \end{aligned}$$

因为 $\sum_{k=1}^n (\hat{\mu}_n - x_k) = n * \hat{\mu}_n - \sum_{k=1}^n x_k = 0$ ，则

$$= \frac{n-1}{n} C_n + YY^t + Z$$

将 Y 、 Z 代入，得

$$C_{n+1} = \frac{n-1}{n} C_n + \frac{1}{n+1} (x_{n+1} - \hat{\mu}_n)(x_{n+1} - \hat{\mu}_n)^t$$

(b)

期望递归计算公式为

$$\hat{\mu}_{n+1} = \hat{\mu}_n + \frac{1}{n+1} (x_{n+1} - \hat{\mu}_n)$$

每次递归是 $O(d)$ 的复杂度，递归 n 次，则总体复杂度为 $O(nd)$ 。方

差递归计算公式为

$$C_{n+1} = \frac{n-1}{n}C_n + \frac{1}{n+1}(x_{n+1} - \hat{\mu}_n)(x_{n+1} - \hat{\mu}_n)^t$$

每次递归是 $O(d^2)$ 的复杂度，递归 n 次，则总体复杂度为 $O(nd^2)$ 。