

第一题

(a)

因为样本 $\mathcal{D} = x_1, \dots, x_n$ 为独立同分布的，所以有：

$$p(\mathcal{D}|\theta) = \prod_{k=1}^n p(x_k|\theta) = \begin{cases} (\frac{1}{\theta})^n, & \forall x \in \mathcal{D}, 0 \leq x \leq \theta \\ 0, & otherwise \end{cases} \quad (1)$$

所以要想使得 $p(\mathcal{D}|\theta)$ 最大，则需要尽可能减小 θ 的值，而当 θ 小于集合 \mathcal{D} 中的某个元素时，概率密度为 0，所以 θ 的最大似然估计为 \mathcal{D} 中的最大值点 $\max[\mathcal{D}]$ 。

(b)

由 (a) 可知，当 $\theta \leq \max[\mathcal{D}]$ 时，概率为 0，其余 4 个点均小于最大值，对于 θ 的估计没有价值，所以无需考虑。且概率密度分布函数为：

$$p(\mathcal{D}|\theta) = \prod_{k=1}^5 p(x_k|\theta) = \begin{cases} (\frac{1}{\theta})^5, & 0.6 \leq \theta \\ 0, & otherwise \end{cases} \quad (2)$$

函数图像如图 1 所示。




图 1: 似然函数 $p(\mathcal{D}|\theta)$ 图像

第二题

(a)

假设样本集为 \mathcal{D} ，容量为 n ，每一个样本点有 d 维特征。根据题目 $\boldsymbol{\mu}$ 的先验概率密度为：

$$p(\boldsymbol{\mu}) = \frac{1}{(2\pi)^{\frac{d}{2}} |\boldsymbol{\Sigma}_0|^{\frac{1}{2}}} \exp\left[-\frac{1}{2}(\boldsymbol{\mu} - \boldsymbol{m}_0)^t |\boldsymbol{\Sigma}_0|^{-1} (\boldsymbol{\mu} - \boldsymbol{m}_0)\right] \quad (3)$$

在样本 $\boldsymbol{x} \in \mathcal{D}$ 下的条件概率密度为：

$$p(\boldsymbol{x}|\boldsymbol{\mu}) = \frac{1}{(2\pi)^{\frac{d}{2}} |\boldsymbol{\Sigma}|^{\frac{1}{2}}} \exp\left[-\frac{1}{2}(\boldsymbol{x} - \boldsymbol{\mu})^t |\boldsymbol{\Sigma}|^{-1} (\boldsymbol{x} - \boldsymbol{\mu})\right] \quad (4)$$

MAP 估计为：

$$\begin{aligned} \hat{\boldsymbol{\mu}}_{MAP} &= \operatorname{argmax}_{\boldsymbol{\mu}} p(\boldsymbol{\mu}) p(\mathcal{D}|\boldsymbol{\mu}) \\ &= \operatorname{argmax}_{\boldsymbol{\mu}} L(\boldsymbol{\mu}|\mathcal{D}) + \ln(p(\boldsymbol{\mu})) \\ &= \operatorname{argmax}_{\boldsymbol{\mu}} \sum_{\boldsymbol{x} \in \mathcal{D}} \ln p(\boldsymbol{x}|\boldsymbol{\mu}) + \ln(p(\boldsymbol{\mu})) \\ &= \operatorname{argmax}_{\boldsymbol{\mu}} n \times \ln\left(\frac{1}{(2\pi)^{\frac{d}{2}} |\boldsymbol{\Sigma}|^{\frac{1}{2}}}\right) + \sum_{\boldsymbol{x} \in \mathcal{D}} \left(-\frac{1}{2}(\boldsymbol{x} - \boldsymbol{\mu})^t |\boldsymbol{\Sigma}|^{-1} (\boldsymbol{x} - \boldsymbol{\mu})\right) \\ &\quad + \ln\left(\frac{1}{(2\pi)^{\frac{d}{2}} |\boldsymbol{\Sigma}_0|^{\frac{1}{2}}}\right) + \left(-\frac{1}{2}(\boldsymbol{\mu} - \boldsymbol{m}_0)^t |\boldsymbol{\Sigma}_0|^{-1} (\boldsymbol{\mu} - \boldsymbol{m}_0)\right) \\ &= \operatorname{argmax}_{\boldsymbol{\mu}} Z + \sum_{\boldsymbol{x} \in \mathcal{D}} \left(-\frac{1}{2}(\boldsymbol{x} - \boldsymbol{\mu})^t |\boldsymbol{\Sigma}|^{-1} (\boldsymbol{x} - \boldsymbol{\mu})\right) - \frac{1}{2}(\boldsymbol{\mu} - \boldsymbol{m}_0)^t |\boldsymbol{\Sigma}_0|^{-1} (\boldsymbol{\mu} - \boldsymbol{m}_0) \end{aligned} \quad (5)$$

其中 Z 为常数项，与 $\boldsymbol{\mu}$ 无关，只需要将式 (5) 中的第 2、3 项之和最大即可。

(b)

对于线性变换 $\boldsymbol{x}' = \boldsymbol{A}\boldsymbol{x}$ ，设其均值和方差分别为 $\boldsymbol{\mu}'$ 和 $\boldsymbol{\Sigma}'$ ，则有：

$$\boldsymbol{\mu}' = \varepsilon(\boldsymbol{x}') = \varepsilon(\boldsymbol{A}\boldsymbol{x}) = \boldsymbol{A}\boldsymbol{\mu} \quad (6)$$

$$\begin{aligned}
\Sigma' &= \varepsilon[(\mathbf{x}' - \boldsymbol{\mu}')(\mathbf{x}' - \boldsymbol{\mu}')^t] \\
&= \varepsilon[(\mathbf{A}\mathbf{x} - \mathbf{A}\boldsymbol{\mu})(\mathbf{A}\mathbf{x} - \mathbf{A}\boldsymbol{\mu})^t] \\
&= \varepsilon\{\mathbf{A}(\mathbf{x} - \boldsymbol{\mu})[\mathbf{A}(\mathbf{x} - \boldsymbol{\mu})]^t\} \\
&= \varepsilon[\mathbf{A}(\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})^t \mathbf{A}^t] \\
&= \mathbf{A}\Sigma\mathbf{A}^t
\end{aligned} \tag{7}$$

由式 (3)、(6)、(7) 可得 $\boldsymbol{\mu}'$ 的先验概率密度为：

$$\begin{aligned}
p(\boldsymbol{\mu}') &= \frac{1}{(2\pi)^{\frac{d}{2}}|\Sigma'_0|^{\frac{1}{2}}} \exp\left[-\frac{1}{2}(\boldsymbol{\mu}' - \mathbf{m}'_0)^t |\Sigma'_0|^{-1} (\boldsymbol{\mu}' - \mathbf{m}'_0)\right] \\
&= \frac{1}{(2\pi)^{\frac{d}{2}}|\Sigma'_0|^{\frac{1}{2}}} \exp\left[-\frac{1}{2}(\mathbf{A}\boldsymbol{\mu} - \mathbf{A}\mathbf{m}_0)^t |\mathbf{A}\Sigma_0\mathbf{A}^t|^{-1} (\mathbf{A}\boldsymbol{\mu} - \mathbf{A}\mathbf{m}_0)\right] \\
&= \frac{1}{(2\pi)^{\frac{d}{2}}|\Sigma'_0|^{\frac{1}{2}}} \exp\left[-\frac{1}{2}(\boldsymbol{\mu} - \mathbf{m}_0)^t \mathbf{A}^t (\mathbf{A}^t)^{-1} |\Sigma_0|^{-1} \mathbf{A}^{-1} \mathbf{A} (\boldsymbol{\mu} - \mathbf{m}_0)\right] \\
&= \frac{1}{(2\pi)^{\frac{d}{2}}|\Sigma'_0|^{\frac{1}{2}}} \exp\left[-\frac{1}{2}(\boldsymbol{\mu} - \mathbf{m}_0)^t |\Sigma_0|^{-1} (\boldsymbol{\mu} - \mathbf{m}_0)\right]
\end{aligned} \tag{8}$$

同理，得在样本 $\mathbf{x}' \in \mathcal{D}'$ 下的条件概率密度为：

$$\begin{aligned}
p(\mathbf{x}' | \boldsymbol{\mu}') &= \frac{1}{(2\pi)^{\frac{d}{2}}|\Sigma'|^{\frac{1}{2}}} \exp\left[-\frac{1}{2}(\mathbf{x}' - \boldsymbol{\mu}')^t |\Sigma'|^{-1} (\mathbf{x}' - \boldsymbol{\mu}')\right] \\
&= \frac{1}{(2\pi)^{\frac{d}{2}}|\Sigma'|^{\frac{1}{2}}} \exp\left[-\frac{1}{2}(\mathbf{A}\mathbf{x} - \mathbf{A}\boldsymbol{\mu})^t |\mathbf{A}\Sigma\mathbf{A}^t|^{-1} (\mathbf{A}\mathbf{x} - \mathbf{A}\boldsymbol{\mu})\right] \\
&= \frac{1}{(2\pi)^{\frac{d}{2}}|\Sigma'|^{\frac{1}{2}}} \exp\left[-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^t \mathbf{A}^t (\mathbf{A}^t)^{-1} |\Sigma|^{-1} \mathbf{A}^{-1} \mathbf{A} (\mathbf{x} - \boldsymbol{\mu})\right] \\
&= \frac{1}{(2\pi)^{\frac{d}{2}}|\Sigma'|^{\frac{1}{2}}} \exp\left[-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^t |\Sigma|^{-1} (\mathbf{x} - \boldsymbol{\mu})\right]
\end{aligned} \tag{9}$$

MAP 估计为：

$$\begin{aligned}
\hat{\boldsymbol{\mu}}'_{MAP} &= \underset{\boldsymbol{\mu}'}{\operatorname{argmax}} p(\boldsymbol{\mu}') p(\mathbf{x}' | \boldsymbol{\mu}') \\
&= \underset{\boldsymbol{\mu}'}{\operatorname{argmax}} L(\boldsymbol{\mu}' | \mathcal{D}') + \ln(p(\boldsymbol{\mu}')) \\
&= \underset{\boldsymbol{\mu}}{\operatorname{argmax}} Z' + \sum_{\mathbf{x} \in \mathcal{D}'} \left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^t |\Sigma|^{-1} (\mathbf{x} - \boldsymbol{\mu})\right) - \frac{1}{2}(\boldsymbol{\mu} - \mathbf{m}_0)^t |\Sigma_0|^{-1} (\boldsymbol{\mu} - \mathbf{m}_0)
\end{aligned} \tag{10}$$

其中 Z' 为常数项, 与 μ' 无关, 只需要将式 (10) 中的第 2、3 项之和最大即可。我们发现, 这个优化目标与估计 μ 的目标是相同的, 所以 MAP 能够对变换后的 μ' 做出正确的估计。

第三题

(a)

$$\begin{aligned}
 Q(\boldsymbol{\theta}; \boldsymbol{\theta}^0) &= \varepsilon_{32} [\ln p(\mathbf{x}_g, \mathbf{x}_b; \boldsymbol{\theta}) | \boldsymbol{\theta}^0; \mathcal{D}_g] \\
 &= \int_{-\infty}^{\infty} \left[\sum_{k=1}^2 \ln p(\mathbf{x}_k | \boldsymbol{\theta}) + \ln p(\mathbf{x}_3 | \boldsymbol{\theta}) \right] p(x_{32} | \boldsymbol{\theta}^0; x_{31} = 2) dx_{32} \\
 &= \sum_{k=1}^2 \ln p(\mathbf{x}_k | \boldsymbol{\theta}) + \int_{-\infty}^{\infty} \ln \left[p\left(\begin{pmatrix} 2 \\ x_{32} \end{pmatrix} | \boldsymbol{\theta}\right) \frac{p\left(\begin{pmatrix} 2 \\ x_{32} \end{pmatrix} | \boldsymbol{\theta}^0\right)}{\int_{-\infty}^{\infty} p\left(\begin{pmatrix} 2 \\ x'_{32} \end{pmatrix} | \boldsymbol{\theta}^0\right) dx_{32}'} \right] dx_{32}
 \end{aligned} \tag{11}$$

其中

$$\begin{aligned}
 \int_{-\infty}^{\infty} p\left(\begin{pmatrix} 2 \\ x'_{32} \end{pmatrix} | \boldsymbol{\theta}^0\right) dx_{32}' &= \int_0^{\theta_2^0} \frac{1}{\theta_1^0} e^{-\frac{2}{\theta_1^0}} \cdot \frac{1}{\theta_2^0} dx_{32} \\
 &= \int_0^4 \frac{1}{2} \cdot e^{-1} \cdot \frac{1}{4} dx_{32} \\
 &= (2e)^{-1}
 \end{aligned}$$

所以

$$\begin{aligned}
 \text{式 (11)} &= \sum_{k=1}^2 \ln p(\mathbf{x}_k | \boldsymbol{\theta}) + 2e \cdot \int_{-\infty}^{\infty} \ln \left[p\left(\begin{pmatrix} 2 \\ x_{32} \end{pmatrix} | \boldsymbol{\theta}\right) p\left(\begin{pmatrix} 2 \\ x_{32} \end{pmatrix} | \boldsymbol{\theta}^0\right) \right] dx_{32} \\
 &= \ln p(\mathbf{x}_1 | \boldsymbol{\theta}) + \ln p(\mathbf{x}_2 | \boldsymbol{\theta}) + K \\
 &= \ln\left(\frac{e^{-1/\theta_1}}{\theta_1 \theta_2}\right) + \ln\left(\frac{e^{-3/\theta_1}}{\theta_1 \theta_2}\right) + K \\
 &= -\frac{4}{\theta_1} - 2\ln(\theta_1 \theta_2) + K
 \end{aligned}$$

对于 K 有 3 种情况。因为 $x_{22} = 3$ 又由于 $p(x_2) \sim \mathcal{U}(0, \theta_2)$ 所以当 $\theta_2 < 3$ 时, $K = 0$ 。又因为 $\theta_2^0 = 4$, 所以如果 $\theta_2 > 4$, 只有 $x_{32} \leq 4$ 的时候, 项

$$p\left(\begin{pmatrix} 2 \\ x_{32} \end{pmatrix} | \boldsymbol{\theta}^0\right)$$

才不为 0，所以：

$$Q(\boldsymbol{\theta}; \boldsymbol{\theta}^0) = \begin{cases} -\frac{4}{\theta_1} - 2\ln(\theta_1\theta_2) - \frac{\theta_2}{4}(\ln(\theta_1\theta_2) + \frac{2}{\theta_1}), & 3 \leq \theta_2 < 4 \\ -\frac{6}{\theta_1} - 3\ln(\theta_1\theta_2), & \theta_2 \geq 4 \\ -\frac{4}{\theta_1} - 2\ln(\theta_1\theta_2), & otherwise \end{cases} \quad (12)$$

(b)

(1) 当 $3 \leq \theta_2 < 4$ 时， Q 为：

$$Q(\boldsymbol{\theta}; \boldsymbol{\theta}^0) = -\frac{1}{\theta_1}(4 + \frac{\theta_2}{2}) - \ln(\theta_1\theta_2)(2 + \frac{\theta_2}{4})$$

将 Q 对 θ_1 求偏导可得：

$$\frac{\partial Q(\boldsymbol{\theta}; \boldsymbol{\theta}^0)}{\partial \theta_1} = -\frac{1}{\theta_1^2}(4 + \frac{\theta_2}{2} - 2\theta_1 - \frac{\theta_1\theta_2}{4}) \quad (13)$$

令式 (13) 为 0，得：

$$(\theta_1 - 2)(-\frac{\theta_2}{4} - 2) = 0$$

则 $\theta_1 = 2$ 或 $\theta_2 = -8$ ，又因为 $3 \leq \theta_2 < 4$ ，所以 $\theta_1 = 2$ 。将 Q 对 θ_2 求偏导可得：

$$\begin{aligned} \frac{\partial Q(\boldsymbol{\theta}; \boldsymbol{\theta}^0)}{\partial \theta_2} &= \frac{1}{4} + \frac{1}{2\theta_1} - \frac{2}{\theta_2} - \frac{1}{4}\ln(\theta_1\theta_2) \\ \text{将 } \theta_1 = 2 \text{ 代入，则原式} &= \frac{2 - \ln\theta_2}{4} - \frac{2}{\theta_2} \end{aligned} \quad (14)$$

当 $3 \leq \theta_2 < 4$ 时，式 (14) 的值小于 0，所以 $Q(\boldsymbol{\theta}; \boldsymbol{\theta}^0)$ 对于 θ_2 单调递减。当 $\theta_2 = 3$ 时， Q 取得最大值。此时 $Q \simeq -7.677$ 。

(2) 当 $\theta_2 \geq 4$ 时， Q 为：

$$Q(\boldsymbol{\theta}; \boldsymbol{\theta}^0) = -\frac{6}{\theta_1} - 3\ln(\theta_1\theta_2)$$

将 Q 对 θ_1 求偏导可得：

$$\frac{\partial Q(\boldsymbol{\theta}; \boldsymbol{\theta}^0)}{\partial \theta_1} = \frac{6 - 3\theta_1}{\theta_1^2} \quad (15)$$

令式 (15) 为 0，得 $\theta_1 = 2$ 。将 Q 对 θ_2 求偏导可得：

$$\frac{\partial Q(\boldsymbol{\theta}; \boldsymbol{\theta}^0)}{\partial \theta_2} = -\frac{3}{\theta_2} \quad (16)$$

当 $\theta_2 \geq 4$ 时，式 (16) 的值恒小于 0，所以 $Q(\boldsymbol{\theta}; \boldsymbol{\theta}^0)$ 对于 θ_2 单调递减。
 当 $\theta_2 = 4$ 时， Q 取得最大值。此时 $Q \simeq -9.238$ 。其他情况没有意义，所以综上所述，当 $\boldsymbol{\theta} = \{2, 3\}$ 时， Q 最大，最大值约为 -7.677 。

第四题

假设第 t 时刻的观测状态值为 v_k ，定义从状态 $\omega_i(t-1)$ 转移到状态 $\omega_j(t)$ 的概率 $\gamma_{ij}(t)$ 为：

$$\gamma_{ij}(t) = \frac{\alpha_i(t-1)a_{ij}b_{jk}\beta_j(t)}{P(\mathbf{V}^T|\boldsymbol{\theta})} \quad (17)$$

其中， $P(\mathbf{V}^T|\boldsymbol{\theta})$ 是模型产生观测序列 \mathbf{V}^T 的总概率。 $\alpha_i(t-1)$ 为前向概率，表示我们的 HMM 在 $t-1$ 时刻，位于隐状态 ω_i ，并已产生观测序列 \mathbf{V}^T 的前 $t-1$ 个观测状态的概率。 $\beta_j(t)$ 为后向概率，表示我们的 HMM 在 t 时刻，位于隐状态 ω_j ，并已产生观测序列 \mathbf{V}^T 中的 $[t+1, \dots, T]$ 观测状态的概率。对 a_{ij} 进行估计，在任何时刻，序列中从状态 $\omega_i(t-1)$ 转移到状态 $\omega_j(t)$ 的预期值为 $\sum_{t=1}^T \gamma_{ij}(t)$ 。而从 ω_i 转移到任何隐状态的总预期数为 $\sum_{t=1}^T \sum_{k=1}^c \gamma_{ik}(t)$ 。所以，

$$\begin{aligned} \hat{a}_{ij} &= \frac{\sum_{t=1}^T \gamma_{ij}(t)}{\sum_{t=1}^T \sum_{k=1}^c \gamma_{ik}(t)} \\ &= \frac{\sum_{t=1}^T \alpha_i(t-1)a_{ij}b_{jk}\beta_j(t)}{\sum_{t=1}^T \alpha_i(t-1)\beta_i(t-1)} \end{aligned} \quad (18)$$

对于某个确定的 i ，计算前向概率 $\alpha_i(t)$ ，需要考虑 $t-1$ 时刻的所有可能的 c 种隐状态的前向概率加权求和，即复杂度为 $\mathcal{O}(c)$ 。式 (18) 中对 t 求和，且对于每一个 i 都要计算一次，则 \hat{a}_{ij} 中计算前向概率的总体复杂度为 $\mathcal{O}(c^2T)$ 。又由于后向概率计算复杂度与前向概率相同全部，所以全部更新一次 \hat{a}_{ij} 的计算复杂度是 $\mathcal{O}(c^2T)$ 。

b_{jk} 为在隐状态 ω_i 的情况下，发出可见状态 v_k 的概率。在任意处于隐状态 ω_j 的时刻，序列中发出观测状态的预计值为 $\sum_{v(t)=v_k, t=1}^T \sum_{l=0}^c \gamma_{jl}(t)$ 。而隐状态 ω_j 发出所有可见状态的总预期数为 $\sum_{t=1}^T \sum_{l=0}^c \gamma_{jl}(t)$ 。所

以,

$$\begin{aligned}
 \hat{b}_{jk} &= \frac{\sum_{v(t)=v_k, t=1}^T \sum_{l=0}^c \gamma_{jl}(t)}{\sum_{t=1}^T \sum_{l=0}^c \gamma_{jl}(t)} \\
 &= \frac{\sum_{t=1}^T \alpha_j(t) \beta_j(t) \delta(t, v_k)}{\sum_{t=1}^T \alpha_j(t) \beta_j(t)}
 \end{aligned} \tag{19}$$

其中, $\delta(t, v_k)$ 是关于 t 和 v_k 的冲击函数, 当在 t 时刻观测状态为 v_k 时, 函数值为 1, 否则为 0。同上, 全部更新一次 \hat{b}_{jk} 的计算复杂度是 $\mathcal{O}(c^2T)$ 。

第五题

根据题意，得

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right] \quad (20)$$

$$\varphi(x) = \frac{1}{\sqrt{2\pi}} \exp\left[-\frac{x^2}{2}\right] \quad (21)$$

(a)

$$\begin{aligned} \bar{p}_n(x) &= \varepsilon[p_n(x)] \\ &= \frac{1}{nh_n} \sum_{i=1}^n \varepsilon\left[\varphi\left(\frac{x-x_i}{h_n}\right)\right] \\ &= \frac{1}{h_n} \int_{-\infty}^{\infty} \varphi\left(\frac{x-v}{h_n}\right) p(v) dv \\ &= \frac{1}{2\pi h_n \sigma} \int_{-\infty}^{\infty} \exp\left[-\frac{1}{2}\left(\frac{x-v}{h_n}\right)^2 - \frac{1}{2}\left(\frac{v-\mu}{\sigma}\right)^2\right] dv \\ &= Z \cdot \int_{-\infty}^{\infty} \exp\left\{-\frac{1}{2}\left[v^2\left(\frac{1}{h_n^2} + \frac{1}{\sigma^2}\right) - 2v\left(\frac{x}{h_n^2} + \frac{\mu}{\sigma^2}\right)\right]\right\} dv \\ &= Z' \cdot \int_{-\infty}^{\infty} \exp\left[-\frac{1}{2}\left(v\sqrt{\frac{1}{h_n^2} + \frac{1}{\sigma^2}} - \frac{\frac{x}{h_n^2} + \frac{\mu}{\sigma^2}}{\sqrt{\frac{1}{h_n^2} + \frac{1}{\sigma^2}}}\right)^2\right] dv \\ &= Z' \cdot \int_{-\infty}^{\infty} \exp\left[-\frac{1}{2}\left(\frac{v-\alpha}{\theta}\right)^2\right] dv \end{aligned} \quad (22)$$

其中 Z' 是与 v 无关的项，且：

$$\begin{aligned} \theta &= \frac{1}{\sqrt{\frac{1}{h_n^2} + \frac{1}{\sigma^2}}} \\ \alpha &= \theta^2 \cdot \left(\frac{x}{h_n^2} + \frac{\mu}{\sigma^2}\right) \\ Z' &= \frac{1}{2\pi h_n \sigma} \exp\left[-\frac{1}{2}\left(\frac{x^2}{h_n^2} + \frac{\mu^2}{\sigma^2}\right) - \frac{\alpha^2}{\theta^2}\right] \end{aligned} \quad (23)$$

换元解得积分项为：

$$\begin{aligned}\int_{-\infty}^{\infty} \exp[-\frac{1}{2}(\frac{v-\alpha}{\theta})^2] dv &= \theta \cdot \int_{-\infty}^{\infty} \exp[-\frac{1}{2}(\frac{v-\alpha}{\theta})^2] d(\frac{v-\alpha}{\theta}) \\ &= \theta \cdot \sqrt{2\pi}\end{aligned}\quad (24)$$

将式 (23)、(24) 代入式 (22) 得，

$$\bar{p}_n(x) = \frac{\theta}{\sqrt{2\pi}h_n\sigma} \exp[-\frac{1}{2}(\frac{x^2}{h_n^2} + \frac{\mu^2}{\sigma^2} - \frac{\alpha^2}{\theta^2})] \quad (25)$$

其中，

$$\begin{aligned}&\frac{x^2}{h_n^2} + \frac{\mu^2}{\sigma^2} - \frac{\alpha^2}{\theta^2} \\ &= \frac{x^2}{h_n^2} + \frac{\mu^2}{\sigma^2} - \frac{\frac{x^2\sigma^2}{h_n^2} + \frac{\mu^2h_n^2}{\sigma^2} + 2x\mu}{h_n^2 + \sigma^2} \\ &= \frac{x^2(h_n^2 + \sigma^2)}{h_n^2(h_n^2 + \sigma^2)} - \frac{x^2\sigma^2 + \frac{\mu^2h_n^4}{\sigma^2} + 2x\mu h_n^2}{(h_n^2 + \sigma^2)h_n^2} + \frac{\mu^2(h_n^2 + \sigma^2)}{\sigma^2(h_n^2 + \sigma^2)} \quad (26) \\ &= \frac{x^2 + 2x\mu - \mu^2}{h_n^2 + \sigma^2} \\ &= \frac{(x - \mu)^2}{h_n^2 + \sigma^2}\end{aligned}$$

将式 (26)、(23) 代入式 (25) 得，

$$\bar{p}_n(x) = \sqrt{\frac{1}{2\pi(h_n^2 + \sigma^2)}} \exp[-\frac{1}{2} \cdot \frac{(x - \mu)^2}{(h_n^2 + \sigma^2)}] \quad (27)$$

所以 $\bar{p}_n(x) \sim N(\mu, \sigma^2 + h_n^2)$ 。

(b)

根据方差公式,

$$\begin{aligned}
 Var[p_n(x)] &= Var[\frac{1}{nh_n} \sum_{i=1}^n \varepsilon[\varphi(\frac{x-x_i}{h_n})]] \\
 &= \frac{1}{nh_n^2} Var[\varepsilon[\varphi(\frac{x-x_i}{h_n})]] \\
 &= \frac{1}{nh_n^2} \cdot \{\varepsilon[\varphi(\frac{x-x_i}{h_n})^2] - (\varepsilon[\varphi(\frac{x-x_i}{h_n})])^2\}
 \end{aligned} \tag{28}$$

其中,

$$\begin{aligned}
 \varepsilon[\varphi(\frac{x-x'}{h_n})^2] &= \int_{-\infty}^{\infty} \varphi(\frac{x-x'}{h_n})^2 p(x') dx' \\
 &= \int_{-\infty}^{\infty} \frac{1}{2\pi} \exp[-(\frac{x-x'}{h_n})^2] \cdot \frac{1}{\sqrt{2\pi}\sigma} \exp[-\frac{1}{2}(\frac{x'-\mu}{h_n})^2] dx' \\
 &= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} \exp\left[-\frac{1}{2}\left(\frac{x-x'}{h_n/\sqrt{2}}\right)^2\right] \exp\left[-\frac{1}{2}\left(\frac{x'-\mu}{\sigma}\right)^2\right] \frac{1}{\sqrt{2\pi}\sigma} dx' \\
 &= \frac{h_n/\sqrt{2}}{\sqrt{2\pi}} \frac{1}{\sqrt{2\pi}\sqrt{h_n^2/2} + \sigma^2} \exp\left[-\frac{1}{2}\frac{(x-\mu)^2}{h_n^2/2 + \sigma^2}\right]
 \end{aligned} \tag{29}$$

结合式 (28), 则有,

$$\begin{aligned}
 \frac{1}{nh_n^2} \cdot \varepsilon[\varphi(\frac{x-x_i}{h_n})^2] &= \frac{1}{nh_n^2} \frac{h_n/\sqrt{2}}{\sqrt{2\pi}} \frac{1}{\sqrt{2\pi}\sqrt{h_n^2/2} + \sigma^2} \exp\left[-\frac{1}{2}\frac{(x-\mu)^2}{h_n^2/2 + \sigma^2}\right] \\
 &= \frac{1}{nh_n} \frac{1}{2\sqrt{\pi}} \frac{1}{\sqrt{2\pi}\sqrt{h_n^2/2} + \sigma^2} \exp\left[-\frac{1}{2}\frac{(x-\mu)^2}{h_n^2/2 + \sigma^2}\right]
 \end{aligned} \tag{30}$$

由窗函数性质, 当 n 趋近于无穷大时, $\sqrt{h_n^2/2} + \sigma^2 \simeq \sigma^2$, 所以,

$$\frac{1}{nh_n^2} \cdot \varepsilon[\varphi(\frac{x-x_i}{h_n})^2] \simeq \frac{1}{2nh_n\sqrt{\pi}} p(x) \tag{31}$$

同理计算均值的平方,

$$\begin{aligned}
 \frac{1}{nh_n^2} \cdot (\varepsilon[\varphi(\frac{x-x_i}{h_n})])^2 &= \frac{1}{nh_n^2} \left[\int \varphi\left(\frac{x-x'}{h_n}\right) p(x') dx' \right]^2 \\
 &= \frac{h_n}{nh_n \sqrt{2\pi} \sqrt{h_n^2 + \sigma^2}} \exp\left[-\frac{1}{2} \frac{(x-\mu)^2}{h_n^2 + \sigma^2}\right] \\
 \text{同理, } &\simeq \frac{h_n}{nh_n \sqrt{2\pi} \sigma} \exp\left[-\frac{1}{2} \frac{(x-\mu)^2}{\sigma^2}\right] \\
 &\simeq 0
 \end{aligned} \tag{32}$$

证毕。

第六题

(a)

假设这些样本点服从均匀分布，且设超立方体的体积为 V ，则每个样本点的邻域可以看成是一个体积为 V/n 的小立方体，该小立方体的边长为 $(V/n)^{\frac{1}{d}}$ 。所以当使用题目中的部分距离表示，投影到 r 维空间时，小超立方体体积变为 $(V/n)^{\frac{r}{d}}$ 。所以在 r 维空间中，某样本点落入体积 V 的概率为：

$$P(x = x^{r'}) = (1/n)^{r/d} \quad (33)$$

所以错分概率为：

$$p(x = x^{d'} | x = x^{r'}) = \frac{(1/n)}{(1/n)^{\frac{r}{d}}} = (1/n)^{1-\frac{r}{d}} = (1/n)^{1-\frac{r}{10}} \quad (34)$$

当 $n = 10$ 时函数图像如下：






图 2: n=10


当 $n = 100$ 时函数图像如下：

图 3: $n=100$

当 $n = 1000$ 时函数图像如下:

图 4: $n=1000$

当 $n = 10000$ 时函数图像如下:

图 5: $n=10000$

可以看到，随着 n 的增大，估计会越来越准确。

(b)

线性斜坡函数定义为：

$$f(x) = \begin{cases} x, & x \geq 0 \\ 0, & x < 0 \end{cases} \quad (35)$$

显然在一维特征下的贝叶斯决策面为

$$x^* = 0.5$$